

隠れマルコフモデル

正田 備也

masada@rikkyo.ac.jp

Contents

マルコフモデル

隠れマルコフモデル

Forward-backward アルゴリズム

マルコフモデル

- ▶ $z = (z_1, \dots, z_T)$ という確率変数の列がある
- ▶ z_t は、状態の集合 $\mathcal{S} = \{s_1, \dots, s_K\}$ の要素を値としてとる
 - ▶ 例えば、 \mathcal{S} は天候の集合だとする
- ▶ 以下の（単純）マルコフ性の仮定をおく

$$p(z_i = s | z_1, \dots, z_{i-1}) = p(z_i = s | z_{i-1}) \text{ for all } s \in \mathcal{S} \quad (1)$$

- ▶ また、 s_k から s_l に遷移する確率 $p(z_t = s_l | z_{t-1} = s_k)$ は全ての t で等しいと仮定（斉時性）し、この確率を A_{s_k, s_l} と書く
- ▶ $\sum_{l=1}^K A_{s_k, s_l} = 1$ が、すべての k で成り立つ
- ▶ 便宜的に初期状態を確率変数 z_0 で表し、その値を s_0 とする
 - ▶ $A_{s_k, s_0} = 0$ が、すべての k について成り立つ

遷移行列

► 遷移確率をまとめて遷移行列 A として書くと

例. 天候の状態の集合 $\mathcal{S} = \{s_0, s_{\text{sun}}, s_{\text{cloud}}, s_{\text{rain}}\}$

$$A = \begin{bmatrix} & s_0 & s_{\text{sun}} & s_{\text{cloud}} & s_{\text{rain}} \\ s_0 & 0 & 0.33 & 0.33 & 0.33 \\ s_{\text{sun}} & 0 & 0.8 & 0.1 & 0.1 \\ s_{\text{cloud}} & 0 & 0.2 & 0.6 & 0.2 \\ s_{\text{rain}} & 0 & 0.1 & 0.2 & 0.7 \end{bmatrix} \quad (2)$$

cf. <http://cs229.stanford.edu/section/cs229-hmm.pdf>

状態列の尤度

- ▶ 状態の列 $z_{1:T} \equiv (z_1, \dots, z_T)$ の尤度 $p(z_{1:T})$ は

$$\begin{aligned} p(z_{1:T}; A) &= p(z_1, \dots, z_T; A) \\ &= p(z_0, z_1, \dots, z_T; A) \\ &= p(z_T | z_{T-1}, \dots, z_1; A) \cdots p(z_2 | z_1; A) p(z_1 | z_0; A) \\ &= p(z_T | z_{T-1}; A) \cdots p(z_2 | z_1; A) p(z_1 | z_0; A) \\ &= \prod_{t=1}^T p(z_t | z_{t-1}; A) = \prod_{t=1}^T A_{z_{t-1}, z_t} \end{aligned} \tag{3}$$

問. どこで単純マルコフ性の仮定を使っているか？

マルコフモデルの最尤推定

$\ln p(\mathbf{z}_{1:T}; A)$ を最大化することで A を推定する。

$$\ln p(\mathbf{z}_{1:T}; A) = \sum_{t=1}^T \ln A_{z_{t-1}, z_t} = \sum_{t=1}^T \sum_{l=1}^K \sum_{k=1}^K \mathbb{1}(z_{t-1} = s_l \wedge z_t = s_k) \ln A_{s_l, s_k} \quad (4)$$

$\mathbb{1}(\cdot)$ は、括弧内の命題が真のとき 1、偽のとき 0、という意味だとする。

$$\mathcal{L}(A, \{\lambda_k\}) = \sum_{t=1}^T \sum_{l=1}^K \sum_{k=1}^K \mathbb{1}(z_{t-1} = s_l \wedge z_t = s_k) \ln A_{s_l, s_k} + \sum_{l=1}^K \lambda_l \left(1 - \sum_{k=1}^K A_{s_l, s_k}\right) \quad (5)$$

$$\frac{\partial \mathcal{L}(A, \{\lambda_k\})}{\partial A_{s_l, s_k}} = \frac{\sum_{t=1}^T \mathbb{1}(z_{t-1} = s_l \wedge z_t = s_k)}{A_{s_l, s_k}} - \lambda_l \quad (6)$$

$\frac{\partial \mathcal{L}(A, \{\lambda_k\})}{\partial A_{s_l, s_k}} = 0$ より $A_{s_l, s_k} \propto \sum_{t=1}^T \mathbb{1}(z_{t-1} = s_l \wedge z_t = s_k)$ で、 $\sum_{k=1}^K A_{s_l, s_k} = 1$ だから

$$\therefore A_{s_l, s_k} = \frac{\sum_{t=1}^T \mathbb{1}(z_{t-1} = s_l \wedge z_t = s_k)}{\sum_{k=1}^K \sum_{t=1}^T \mathbb{1}(z_{t-1} = s_l \wedge z_t = s_k)} = \frac{\sum_{t=1}^T \mathbb{1}(z_{t-1} = s_l \wedge z_t = s_k)}{\sum_{t=1}^T \mathbb{1}(z_{t-1} = s_l)} \quad (7)$$

Contents

マルコフモデル

隠れマルコフモデル

Forward-backward アルゴリズム

隠れマルコフモデルHMM; hidden Markov model

- ▶ 状態 z_t は観測できず、各状態が生成する結果 x_t だけが観測できるとする
 - ▶ このとき、状態を表す確率変数 z_t は潜在変数 latent variable となる
- ▶ 隠れ状態の列 $\mathbf{z}_{1:T} = (z_1, \dots, z_T)$ は、上述のとおり、単純マルコフ性と斉時性を持つとする
- ▶ 時点 t での観測結果を、確率変数 x_t で表す
- ▶ 観測データ x_t について、以下のような独立性の仮定をおく

$$p(x_t = v_w | \mathbf{x}_{1:T}, \mathbf{z}_{1:T}) = p(x_t = v_w | z_t = s_k) \quad (8)$$


- ▶ つまり、時点 t の観測値は、同じ時点の隠れ状態だけに依存する

観測データがカテゴリカルデータの場合


- ▶ ここでは、観測データはカテゴリカルデータだとする
 - ▶ 観測データが連続値で、 $p(x_t|z_t)$ が、例えば正規分布の場合、以下の議論がどうなるか、考えてみよう
- ▶ 隠れ状態 s_k がであるときの、アイテム v_w の出現確率 $p(x_t = v_w | z_t = s_k)$ を、 B_{s_k, v_w} と書くことにする
 - ▶ $(B_{s_k, v_1}, \dots, B_{s_k, v_W})$ は、状態 s_k に対応するカテゴリカル分布の、パラメータである
 - ▶ $\sum_{w=1}^W B_{s_k, v_w} = 1$ が成り立つ
- ▶ 隠れマルコフモデルにおけるパラメータ推定では、 A と B を推定することになる

混合分布モデルと隠れマルコフモデル

- ▶ 混合分布モデル
 - ▶ 隠れ変数 z_i は独立



- ▶ 隠れマルコフモデル
 - ▶ 隠れ変数 z_t の間に依存関係
 - ▶ 線形で一方向的な依存関係



同時分布

- ▶ 隠れマルコフモデルでの観測変数と隠れ変数の同時分布は

$$\begin{aligned} p(\mathbf{x}_{1:T}, \mathbf{z}_{1:T}; A, B) &= p(\mathbf{x}_{1:T} | \mathbf{z}_{1:T}; B) p(\mathbf{z}_{1:T}; A) \\ &= \prod_{t=1}^T p(x_t | z_t; B) \times \prod_{t=1}^T p(z_t | z_{t-1}; A) \\ &= \prod_{t=1}^T B_{z_t, x_t} \times \prod_{t=1}^T A_{z_{t-1}, z_t} \end{aligned} \quad (9)$$

- ▶ 状態列の確率 $p(\mathbf{z}_{1:T})$ の部分は、式 (3) と同じ
- ▶ ただし、隠れマルコフモデルでは z_t は潜在変数

観測データの尤度

- ▶ 観測データの尤度 $p(\boldsymbol{x}; A, B)$ は

$$\begin{aligned} p(\boldsymbol{x}; A, B) &= \sum_{\boldsymbol{z}} p(\boldsymbol{x}, \boldsymbol{z}; A, B) \\ &= \sum_{z_1 \in \mathcal{S}} \cdots \sum_{z_T \in \mathcal{S}} \left(\prod_{t=1}^T p(x_t | z_t; B) \right) \left(\prod_{t=1}^T p(z_t | z_{t-1}; A) \right) \\ &= \sum_{z_1 \in \mathcal{S}} \cdots \sum_{z_T \in \mathcal{S}} \left(\prod_{t=1}^T B_{z_t, x_t} \right) \left(\prod_{t=1}^T A_{z_{t-1}, z_t} \right) \quad (10) \end{aligned}$$

- ▶ だが、この式をそのまま使って計算すると、計算量が $O(|\mathcal{S}|^T) = O(K^T)$ であるため、非現実的な計算時間になる

Contents

マルコフモデル

隠れマルコフモデル

Forward-backward アルゴリズム

Forward procedure

- ▶ HMM のデータ尤度 $p(\mathbf{x}; A, B)$ は、動的計画法の一種である forward procedure によって、効率的に計算できる

cf. <https://web.stanford.edu/jurafsky/slp3/A.pdf>

- ▶ 時点 t までのデータ列 (x_1, \dots, x_t) の確率と、時点 t での隠れ状態 z_t が s_k である確率の同時確率を、 $\alpha_t(k)$ とおく。つまり

$$\alpha_t(k) \equiv p(x_1, \dots, x_t, z_t = s_k; A, B) \quad (11)$$

- ▶ すると、データ尤度を以下のように表すことができる

$$p(\mathbf{x}; A, B) = \sum_{k=1}^K p(\mathbf{x}_{1:T}, z_T = s_k; A, B) = \sum_{k=1}^K \alpha_T(k) \quad (12)$$

$$\alpha_1(k) = p(x_1, z_1 = s_k) = p(z_0 = s_0)p(z_1 = s_k|z_0 = s_0)p(x_1|z_1 = s_k) = A_{0,k}B_{k,x_1} \quad (13)$$

$$\begin{aligned} \alpha_2(k) &= p(x_1, x_2, z_2 = s_k) = \sum_{z_1 \in \mathcal{S}} p(x_1, x_2, z_1, z_2 = s_k) \\ &= \sum_{z_1 \in \mathcal{S}} p(x_1, z_1)p(z_2 = s_k|x_1, z_1)p(x_2|z_2 = s_k, x_1, z_1) \end{aligned} \quad (14)$$

$$= \sum_{z_1 \in \mathcal{S}} p(x_1, z_1)p(z_2 = s_k|z_1)p(x_2|z_2 = s_k) = \sum_{l=1}^l \alpha_1(l)A_{s_l, s_k}B_{s_k, x_2} \quad (15)$$

$$\begin{aligned} \alpha_3(k) &= p(x_1, x_2, x_3, z_3 = s_k) = \sum_{z_2 \in \mathcal{S}} p(x_1, x_2, x_3, z_2, z_3 = s_k) \\ &= \sum_{z_2 \in \mathcal{S}} p(x_1, x_2, z_2)p(z_3 = s_k|x_1, x_2, z_2)p(x_3|z_3 = s_k, x_1, x_2, z_2) \end{aligned} \quad (16)$$

$$= \sum_{z_2 \in \mathcal{S}} p(x_1, x_2, z_2)p(z_3 = s_k|z_2)p(x_3|z_3 = s_k) = \sum_{l=1}^K \alpha_2(l)A_{s_l, s_k}B_{s_k, x_3} \quad (17)$$

式 (14) から (15)、式 (16) から (17) は、自明でない。→ 条件付き独立性

$$\begin{aligned}
\alpha_t(k) &= p(\mathbf{x}_{1:t}, z_t = s_k) \\
&= \sum_{z_{t-1} \in \mathcal{S}} p(\mathbf{x}_{1:t-1}, x_t, z_{t-1}, z_t = s_k) \\
&= \sum_{z_{t-1} \in \mathcal{S}} p(\mathbf{x}_{1:t-1}, z_{t-1}) p(z_t = s_k | \mathbf{x}_{1:t-1}, z_{t-1}) p(x_t | z_t = s_k, \mathbf{x}_{1:t-1}, z_{t-1}) \quad (18)
\end{aligned}$$

$$= \sum_{z_{t-1} \in \mathcal{S}} p(\mathbf{x}_{1:t}, z_{t-1}) p(z_t = s_k | z_{t-1}) p(x_t | z_t = s_k) = \sum_{l=1}^K \alpha_{t-1}(l) A_{s_l, s_k} B_{s_k, x_t} \quad (19)$$

式 (18) から (19) は、自明でない。下記の条件付き独立性を示す必要あり。

z_{t-1} が所与のもとで z_t と $\mathbf{x}_{1:t-1}$ は条件付き独立。

z_t が所与のもとで x_t と $\mathbf{x}_{1:t-1}, z_{t-1}$ は条件付き独立。

条件付き独立性 conditional independence

- ▶ C が与えられたときに A と B が独立である、つまり、 $p(A, B|C) = p(A|C)p(B|C)$ が成り立つとき、 A と B は C が所与のもとで条件付き独立である、という
- ▶ 条件付き確率の定義より、 $p(A, B|C) = p(A|B, C)p(B|C)$ はいつでも成り立つ。よって

A と B は C が所与のもとで条件付き独立である

$$\Leftrightarrow p(A|B, C) = p(A|C) \quad (20)$$

注. $p(A, B|C) = p(A|C)p(B|C)$ と $P(A, B) = P(A)P(B)$ は別物

問9.1

- ▶ $P(A, B, C|D) = P(A|D)P(B, C|D)$ 、つまり、
 D が所与のもとで A と B, C が条件付き独立ならば、
 $P(A, B|D) = P(A|D)P(B|D)$ 、つまり、
 D が所与のもとで A と B が条件付き独立になることを、
示せ。

答え $P(A, B, C|D) = P(A|D)P(B, C|D)$ の両辺を C について周辺化すると、左辺は $\sum_C P(A, B, C|D) = P(A, B|D)$ となり、
右辺は $\sum_C P(A|D)P(B, C|D) = P(A|D)P(B|D)$ となる。
よって、 $P(A, B|D) = P(A|D)P(B|D)$ が言える。

$p(z_t|z_{t-1}, \mathbf{x}_{1:t-1}) = p(z_t|z_{t-1})$ を示す。

$$p(z_t|z_{t-1}, \mathbf{x}_{1:t-1}) = \frac{p(z_t, z_{t-1}, \mathbf{x}_{1:t-1})}{p(z_{t-1}, \mathbf{x}_{1:t-1})} \quad (21)$$

$$p(z_{t-1}, \mathbf{x}_{1:t-1}) = \sum_{\mathbf{z}_{1:t-2}} \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u) \quad (22)$$

$$\begin{aligned} p(z_t, z_{t-1}, \mathbf{x}_{1:t-1}) &= \sum_{\mathbf{z}_{1:t-2}} p(z_t|z_{t-1}) \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u) \\ &= p(z_t|z_{t-1}) \sum_{\mathbf{z}_{1:t-2}} \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u) \end{aligned} \quad (23)$$

$$\therefore p(z_t|z_{t-1}, \mathbf{x}_{1:t-1}) = \frac{p(z_t|z_{t-1}) \sum_{\mathbf{z}_{1:t-2}} \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u)}{\sum_{\mathbf{z}_{1:t-2}} \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u)} = p(z_t|z_{t-1}) \quad (24)$$

z_{t-1} が所与のもとで z_t と $\mathbf{x}_{1:t-1}$ は条件付き独立であることが言えた。

$p(x_t|z_t, z_{t-1}, \mathbf{x}_{1:t-1}) = p(x_t|z_t)$ を示す。

$$p(x_t|z_t, z_{t-1}, \mathbf{x}_{1:t-1}) = \frac{p(x_t, z_t, z_{t-1}, \mathbf{x}_{1:t-1})}{p(z_t, z_{t-1}, \mathbf{x}_{1:t-1})} \quad (25)$$

式 (23) より

$$\begin{aligned} p(z_t, z_{t-1}, \mathbf{x}_{1:t-1}) &= p(z_t|z_{t-1}) \sum_{\mathbf{z}_{1:t-2}} \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u) \\ p(x_t, z_t, z_{t-1}, \mathbf{x}_{1:t-1}) &= \sum_{\mathbf{z}_{1:t-2}} p(x_t|z_t)p(z_t|z_{t-1}) \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u) \\ &= p(x_t|z_t)p(z_t|z_{t-1}) \sum_{\mathbf{z}_{1:t-2}} \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u) \end{aligned} \quad (26)$$

$$\begin{aligned} \therefore p(x_t|z_t, z_{t-1}, \mathbf{x}_{1:t-1}) &= \frac{p(x_t|z_t)p(z_t|z_{t-1}) \sum_{\mathbf{z}_{1:t-2}} \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u)}{p(z_t|z_{t-1}) \sum_{\mathbf{z}_{1:t-2}} \prod_{u=1}^{t-1} p(z_u|z_{u-1})p(x_u|z_u)} = p(x_t|z_t) \end{aligned} \quad (27)$$

z_t が所与のもとで x_t と $\mathbf{x}_{1:t-1}, z_{t-1}$ は条件付き独立であることが言えた。

隠れマルコフモデルのEM アルゴリズム

- ▶ EM アルゴリズムの導出には、やはり Jensen の不等式を使う

$$\begin{aligned}\ln p(\mathbf{x}_{1:T}) &= \ln \sum_{\mathbf{z}_{1:T}} p(\mathbf{x}_{1:T}, \mathbf{z}_{1:T}) \\ &= \ln \sum_{\mathbf{z}_{1:T}} q(\mathbf{z}_{1:T}) \frac{p(\mathbf{x}_{1:T}, \mathbf{z}_{1:T})}{q(\mathbf{z}_{1:T})} \geq \sum_{\mathbf{z}_{1:T}} q(\mathbf{z}_{1:T}) \ln \frac{p(\mathbf{x}_{1:T}, \mathbf{z}_{1:T})}{q(\mathbf{z}_{1:T})}\end{aligned}$$

- ▶ EM アルゴリズムでは、この下界を最大化する (28)

$$\begin{aligned}A, B &= \arg \max_{A, B} \sum_{\mathbf{z}_{1:T}} q(\mathbf{z}_{1:T}) \ln \frac{p(\mathbf{x}_{1:T}, \mathbf{z}_{1:T})}{q(\mathbf{z}_{1:T})} \\ &= \arg \max_{A, B} \sum_{\mathbf{z}_{1:T}} q(\mathbf{z}_{1:T}) \ln p(\mathbf{x}_{1:T}, \mathbf{z}_{1:T})\end{aligned} \quad (29)$$